

Agente Inteligente para Monitoramento da Qualidade do Ar em Smart Campus

Noedson Romario Vieira da Silva

Resumo

Esta revisão bibliográfica analisa soluções de monitoramento da qualidade do ar aplicadas ao contexto de smart campus, com foco em arquiteturas que combinam Internet das Coisas (IoT), comunicação de longo alcance, inteligência artificial, mecanismos de resposta automatizada e requisitos de tempo real. O estudo examina trabalhos publicados entre 2019 e 2026 para identificar tendências, limitações e oportunidades de integração entre sensoriamento, processamento e atuação sobre o ambiente.

Os resultados indicam que as propostas mais consistentes unem sensores distribuídos, plataformas de integração, análise preditiva e, em alguns casos, sistemas operacionais de tempo real para aumentar a previsibilidade e a confiabilidade do fluxo de dados. Também se observa que o contexto acadêmico exige soluções escaláveis, de baixo custo e capazes de apoiar decisões preventivas em ambientes internos e externos. Com isso, a revisão evidencia a relevância de arquiteturas inteligentes para tornar o monitoramento ambiental mais responsivo, útil e alinhado às necessidades de campus universitários.

Palavras-chave: qualidade do ar; smart campus; Internet das Coisas; inteligência artificial; tempo real.

Abstract

This literature review analyzes air quality monitoring solutions applied to smart campus environments, with emphasis on architectures that combine the Internet of Things (IoT), long-range communication, artificial intelligence, automated response mechanisms, and real-time requirements. The study reviews works published between 2019 and 2026 in order to identify trends, limitations, and opportunities for integrating sensing, processing, and environmental action.

The findings indicate that the most consistent approaches combine distributed sensors, integration platforms, predictive analytics, and, in some cases, real-time operating systems to improve the predictability and reliability of the data flow. The academic context also requires scalable, low-cost solutions capable of supporting preventive decisions in indoor and outdoor spaces. Overall, the review highlights the relevance of intelligent

architectures for making environmental monitoring more responsive, useful, and aligned with the needs of university campuses.

Keywords: air quality; smart campus; Internet of Things; artificial intelligence; real time.

1 Introdução

A qualidade do ar é um fator crítico para a saúde e bem estar das pessoas, especialmente em ambientes internos e de alta ocupação como os campi universitários. Segundo os estudos mais recentes, a exposição prolongada a poluentes atmosféricos como, monóxido de carbono (CO), e Ozônio (O₃) causa impactos significativos na saúde respiratória e cardiovascular da população acadêmica. (Anjos Gomes; Lima; Vale Brisil, 2024) documentam a correlação entre eventos de queimadas na Amazônia e o aumento de casos de problemas respiratórios, demonstrando a relevância de sistemas de monitoramento contínuo e confiável.

Nesse contexto, os campi universitários emergem como ambientes estratégicos para a implantação de soluções inteligentes. O conceito de Smart Campus, como definido por (Min-Allah; Alrashed, 2020), envolve a integração de tecnologias de internet das coisas (IoT) para oferecer suporte à tomada de decisão, segurança e bem-estar da comunidade acadêmica. O monitoramento ambiental em tempo real possibilita a detecção de anomalias, acionamento de sistemas de resposta automatizada e fornecimento de dados à análise preditiva.

As arquiteturas tradicionais de monitoramento, embora funcionais, apresentam limitações em termos de escalabilidade, latência e resposta determinísticas. Soluções genéricas baseadas em IoT (Al., 2019; Kumar; Jasuja, 2017) normalmente não consideram: (i) a necessidade de predição de qualidade do ar em horizonte futuro, (ii) mecanismos de resposta automatizada integrada, (iii) garantias de tempo real através de Sistemas Operacionais de Tempo Real (RTOS), e (iv) adequação específica ao contexto acadêmico.

1.1 Escopo e delimitação

Esta revisão bibliográfica delimita-se ao estudo de soluções voltadas ao monitoramento da qualidade do ar em ambientes de campus universitário, com ênfase em arquiteturas inteligentes capazes de apoiar a coleta, o processamento, a análise e a resposta a dados ambientais em tempo quase real. O foco recai sobre abordagens que combinam Internet das Coisas (IoT), comunicação de longo alcance, plataformas de integração e técnicas de inteligência artificial aplicadas a dados ambientais.

O escopo contempla trabalhos publicados entre 2019 e 2026, incluindo artigos científicos, anais de eventos, revisões e estudos aplicados que tratem de monitoramento da qualidade do ar, sensores ambientais, sistemas embarcados, middleware, comunicação LPWAN, análise preditiva e mecanismos de automação. Também são considerados estu-

dos que abordem a aplicação de sistemas operacionais de tempo real (RTOS) em nós de sensoriamento ou em componentes críticos da arquitetura.

Como delimitação, esta pesquisa não tem como objetivo aprofundar a fabricação ou calibração física dos sensores, nem comparar em detalhe todos os poluentes atmosféricos possíveis. O recorte é direcionado aos poluentes e variáveis mais recorrentes na literatura para ambientes internos e externos, especialmente aqueles associados a impactos respiratórios e ao conforto ambiental. Da mesma forma, soluções sem aderência ao contexto acadêmico ou sem relação direta com monitoramento ambiental são tratadas apenas de forma periférica, quando contribuem para a fundamentação teórica.

2 Fundamentos Teóricos

2.1 Qualidade do ar e impactos

A qualidade do ar é um dos principais indicadores de salubridade ambiental, pois influencia diretamente a saúde respiratória, o desempenho cognitivo e o bem estar de indivíduos expostos por longos períodos. Em ambientes universitários, essa questão ganha relevância adicional porque salas de aula, laboratórios, corredores e áreas comuns concentram grande circulação de pessoas e podem apresentar variações expressivas na concentração de poluentes ao longo do dia. Entre os parâmetros mais monitorados na literatura estão monóxido de carbono (CO), óxidos de nitrogênio (NOx), ozônio (O₃), material particulado fino (PM_{2.5}) e material particulado grosso (PM₁₀), além de temperatura, umidade e dióxido de carbono como variáveis auxiliares.

Estudos recentes reforçam que episódios de degradação da qualidade do ar estão associados ao aumento de problemas respiratórios e à intensificação de sintomas em populações mais vulneráveis. (Anjos Gomes; Lima; Vale Brisil, 2024) mostram a relação entre queimadas na Amazônia e a incidência de doenças respiratórias, o que evidencia a necessidade de sistemas de monitoramento capazes de registrar alterações ambientais com maior frequência e confiabilidade. Nesse cenário, o monitoramento contínuo deixa de ser apenas uma atividade de observação e passa a ser um mecanismo de apoio à prevenção, à emissão de alertas e ao planejamento de respostas institucionais.

2.2 Smart campus

O conceito de smart campus amplia a ideia de digitalização da universidade ao integrar infraestrutura física, serviços computacionais, sensores e plataformas de análise em uma mesma lógica de operação. Nessa perspectiva, o campus deixa de ser apenas um espaço acadêmico e passa a ser um ambiente conectado, capaz de coletar dados sobre mobilidade, consumo de energia, segurança, ocupação e condições ambientais para apoiar decisões mais rápidas e baseadas em evidências (Min-Allah; Alrashed, 2020).

Dentro desse ecossistema, o monitoramento da qualidade do ar ocupa posição estratégica porque impacta diretamente a saúde da comunidade acadêmica e a experiência

de uso dos espaços. Soluções voltadas ao smart campus precisam considerar não apenas a medição dos poluentes, mas também a capacidade de transformar esses dados em informação útil para gestores, professores, estudantes e equipes de manutenção. Assim, a contribuição das arquiteturas inteligentes está em conectar sensoriamento, comunicação e automação em um fluxo contínuo de coleta e resposta.

2.3 IoT para monitoramento ambiental

A Internet das Coisas (IoT) constitui a base técnica de grande parte das soluções de monitoramento ambiental, pois permite conectar sensores distribuídos a plataformas de processamento e visualização. Em uma arquitetura típica, os nós de sensoriamento capturam variáveis físicas do ambiente, um gateway ou nó de borda agrega e encaminha os dados, e uma camada de middleware organiza o fluxo de informações para armazenamento, consulta e integração com aplicações de análise.

No contexto da qualidade do ar, a literatura destaca o uso de arquiteturas distribuídas para ampliar cobertura, reduzir custos e viabilizar monitoramento em tempo mais próximo do real (Al., 2019; CUNHA, 2024). Tecnologias de comunicação de longo alcance, como LoRaWAN, são especialmente úteis quando o objetivo é cobrir áreas extensas com baixo consumo de energia e baixa complexidade de instalação. Já plataformas de integração e orquestração, como FIWARE, Node-RED ou módulos equivalentes, contribuem para a interoperabilidade entre sensores, bancos de dados, dashboards e serviços de notificação.

2.4 Sistemas de tempo real (RTOS)

Sistemas operacionais de tempo real, ou RTOS, são empregados quando a principal exigência do sistema não é apenas executar tarefas, mas executá-las dentro de restrições temporais previsíveis. Em monitoramento ambiental, essa característica é importante porque atrasos no processamento ou no envio de alertas podem comprometer a utilidade da informação, especialmente quando há necessidade de resposta imediata a variações bruscas na qualidade do ar (REDDY, 2023).

A adoção de RTOS em nós sensores permite tratar concorrência, priorização de tarefas, interrupções e comunicação com maior previsibilidade, reduzindo jitter e aumentando a confiabilidade do fluxo de dados. Em trabalhos aplicados, a combinação entre RTOS e IoT aparece como uma estratégia para reforçar a robustez de sistemas embarcados, como observado em soluções de monitoramento ambiental baseadas em FreeRTOS (SEPTIAN; MISBAHUDDIN; ARKAN, 2022; Silva *et al.*, 2025). Dessa forma, o RTOS deixa de ser apenas um componente de infraestrutura e passa a ser um elemento central para garantir responsividade em arquiteturas de monitoramento crítico.

3 Arquiteturas de Monitoramento da Qualidade do Ar

3.1 Soluções IoT gerais

As soluções IoT para monitoramento da qualidade do ar variam de propostas simples, com coleta local e visualização básica, até arquiteturas mais completas, com predição, alertas e integração com plataformas em nuvem. Trabalhos como os de Benammar et al. (BENAMMAR, 2018) e Kumar e Doss (Kumar; Doss, 2023) mostram que a modularidade é um fator recorrente, pois facilita a expansão da rede de sensores, a adaptação a diferentes ambientes e a incorporação de novos serviços analíticos.

Em ambientes internos, as propostas costumam priorizar conforto e segurança ocupacional, enquanto em ambientes externos o foco tende a incluir variabilidade climática, dispersão de poluentes e cobertura territorial. Em ambos os casos, a arquitetura normalmente envolve três camadas principais: percepção, transporte e aplicação. A camada de percepção concentra sensores e microcontroladores; a de transporte realiza a comunicação entre os dispositivos e a infraestrutura central; e a camada de aplicação transforma os dados em indicadores, gráficos, previsões e ações automatizadas.

3.2 Soluções para contexto acadêmico

No contexto acadêmico, a literatura aponta que as soluções precisam atender a requisitos que vão além da simples medição de poluentes. É necessário considerar a dispersão dos edifícios, a ocupação variável dos espaços, a necessidade de baixo custo de manutenção e a integração com rotinas institucionais já existentes. Estudos como os de Cunha et al. (CUNHA, 2024) e Ugarte et al. (UGARTE *et al.*, 2019) indicam que o uso de tecnologias de conectividade de longo alcance pode ser uma resposta adequada para campi com áreas amplas ou com infraestrutura distribuída. O artigo de Silva et al. (Silva *et al.*, 2025) reforça essa direção ao demonstrar uma arquitetura de monitoramento da qualidade do ar em smart campus com foco em tempo real e uso de FreeRTOS para melhorar a transmissão e a recepção dos dados.

Além disso, o contexto universitário favorece o uso de dados para fins pedagógicos e de pesquisa, o que amplia o valor da solução para além da operação predial. Quando o monitoramento é incorporado ao smart campus, a informação pode subsidiar ações de prevenção, apoiar decisões sobre ocupação de ambientes e alimentar painéis de gestão ambiental. Esse alinhamento com as necessidades institucionais é o que torna o cenário acadêmico particularmente relevante para o desenvolvimento da proposta deste trabalho.

3.3 Comparação tecnológica

- Comunicação: LoRaWAN, Wi-Fi, BLE, LTE.
- Middleware: FIWARE, Node-RED, ChirpStack.
- Persistência e visualização: bancos de dados e dashboards.

4 Inteligência Artificial Aplicada à Qualidade do Ar

4.1 Tarefas e técnicas

A inteligência artificial vem sendo incorporada a sistemas de monitoramento ambiental para extrair padrões a partir de dados históricos e apoiar decisões de forma automatizada. No contexto da qualidade do ar, as tarefas mais comuns incluem classificação de situações de risco, previsão de séries temporais, regressão de variáveis ambientais e detecção de anomalias. Essas tarefas permitem que o sistema não apenas registre o estado atual do ambiente, mas também antecipe tendências e identifique comportamentos fora do padrão (Kumar; Doss, 2023).

Em geral, a aplicação de IA depende da qualidade do conjunto de dados, da seleção das variáveis de entrada e da capacidade do modelo de generalizar para condições distintas das observadas durante o treinamento. Em soluções voltadas para o monitoramento da qualidade do ar, isso significa considerar não só os poluentes medidos diretamente, mas também fatores contextuais que influenciam a dispersão e a dinâmica das medições. A literatura recente mostra que modelos inteligentes ganham importância quando são combinados com sensores distribuídos e fluxos contínuos de dados.

4.2 Entradas, saídas e horizonte de previsão

Os modelos aplicados ao monitoramento da qualidade do ar costumam usar como entradas séries temporais de poluentes, variáveis meteorológicas, horários de coleta e, em alguns casos, características do ambiente monitorado. Antes do treinamento, é comum realizar limpeza de dados, normalização, tratamento de valores ausentes e segmentação em janelas temporais. Esse pré-processamento é necessário para reduzir ruídos e tornar as séries mais adequadas à modelagem.

Quanto às saídas, os estudos podem prever valores contínuos de poluentes, classificar níveis de qualidade do ar em faixas de risco ou estimar a ocorrência de eventos críticos em um horizonte de curto e médio prazo. A escolha do horizonte de previsão depende do objetivo do sistema: horizontes curtos favorecem respostas operacionais imediatas, enquanto horizontes maiores ajudam no planejamento preventivo e no uso estratégico dos espaços. Em ambos os casos, a definição adequada da janela temporal influencia diretamente o desempenho do modelo.

4.3 Métricas de avaliação

A avaliação dos modelos de IA em qualidade do ar normalmente combina métricas de erro e de desempenho classificatório. Quando o problema é de regressão ou previsão numérica, métricas como MAE e RMSE são úteis para medir o desvio entre valores previstos e observados. Quando o foco está em classificação de estados ou níveis de risco, métricas como acurácia, precisão, revocação e F1 tornam-se mais apropriadas.

A escolha da métrica deve refletir a finalidade prática da solução. Em aplicações

voltadas à prevenção de risco, por exemplo, a revocação pode ser mais importante do que a acurácia geral, porque perder um evento crítico pode ser mais grave do que gerar um alerta adicional. Por isso, a literatura deve ser lida considerando não apenas os números reportados, mas também o contexto de uso do modelo e o custo associado a cada tipo de erro.

5 Resposta Automatizada e Tempo Real

5.1 Mecanismos de resposta

Os mecanismos de resposta automatizada transformam o monitoramento em uma ação concreta sobre o ambiente. Em vez de apenas registrar a degradação da qualidade do ar, o sistema pode emitir alertas, enviar notificações contextuais para usuários e gestores, acionar ventilação, recomendar evacuação parcial ou registrar eventos para posterior análise. Essa camada de resposta é importante porque aproxima a arquitetura de um sistema de apoio à decisão e não apenas de um sistema de sensoriamento.

Em ambientes universitários, essa resposta pode ser combinada com regras de negócio simples ou com modelos mais sofisticados de inferência, permitindo adaptar a ação ao nível de risco observado. Quanto mais integrado estiver o fluxo entre detecção, análise e atuação, menor tende a ser o tempo entre a identificação do problema e a resposta operacional.

O estudo de Silva et al. (Silva *et al.*, 2025) é particularmente relevante porque mostra que o uso de RTOS em uma arquitetura de qualidade do ar para smart campus não é apenas uma escolha de implementação, mas um fator que impacta diretamente o desempenho de comunicação e de notificação em tempo real.

5.2 Garantias de tempo real

Garantias de tempo real envolvem a capacidade de respeitar prazos de execução, manter latência previsível e reduzir variações de resposta em cenários de operação contínua. Em sistemas de monitoramento ambiental, isso é relevante porque o valor da informação está diretamente ligado à sua tempestividade. Atrasos excessivos podem fazer com que o alerta chegue depois do pico de exposição, reduzindo o impacto da solução.

Nesse sentido, o RTOS contribui para organizar tarefas concorrentes, priorizar rotinas críticas e estabilizar o comportamento do nó sensor ou do controlador local (SEPTIAN; MISBAHUDDIN; ARKAN, 2022; WANG *et al.*, 2023). Em conjunto com a comunicação eficiente e com políticas claras de emissão de alertas, essas garantias ajudam a construir uma arquitetura mais confiável para o monitoramento da qualidade do ar em tempo quase real.

6 Análise Comparativa dos Trabalhos

Formulação da(s) pergunta(s) da revisão:

- Quais arquiteturas IoT (sensores, gateways LoRaWAN, middleware, nuvem) têm sido usadas para monitorar qualidade do ar em smart campuses (ex.: CUNHA (2024))?
- Quais algoritmos de IA/ML são aplicados para predição de curto prazo (próximas horas) de poluentes em ambientes internos/externos (ex.: Kumar e Doss (2023), Thaylor *et al.* (2025))?
- Existem soluções que integram RTOS em nós sensores para garantir respostas determinísticas em monitoramento de qualidade do ar (ex.: SEPTIAN, MISBAHUDDIN e ARKAN (2022), Alves *et al.* (2025))?
- Como agentes inteligentes são utilizados para interpretar dados de qualidade do ar, identificar situações de risco e acionar respostas automatizadas?

Fonte(s): IEEE Xplore, e Google Scholar, Periódico CAPES, Scopus, Web of Science

Data/período da Busca: 2020 – 2026

Intervalo de tempo da busca: 6 anos

Palavras-chave:

Palavra-chave em Português	Sinônimos em Português	Palavra-chave em Inglês	Sinonimos em Inglês
Qualidade do ar	Condição do ar ambiente, Nível de poluição do ar	Air quality	Ambient air quality, Air Pollution, Atmospheric quality
Smart campus	Campus inteligente, campus conectado	Smart campus	Intelligent campus, Connected campus, Digital campus
IoT	Internet das Coisas, Dispositivos conectados, redes de sensores	IoT	Internet of Things, IoT Systems, Smart Devices
LoRaWAN	Rede LPWAN de longo alcance, Infraestrutura LoRaWAN para IoT	LoRaWAN	LoRaWAN Network, LoRaWAN Infrastructure
FIWARE	Plataforma de gerenciamento de contexto FIWARE, middleware FIWARE para IoT	FIWARE	FIWARE Platform, IoT Middleware
Predição de poluentes	Predição de curto prazo de poluentes	Short-term pollutant prediction	Short-term Air Quality Prediction

String de busca (inglês):

- (("air quality" OR "air pollution" OR "indoor air quality") AND ("smart campus" OR "university campus" OR "higher education") AND ("IoT" OR "LoRaWAN" OR "FIWARE" OR "ChirpStack") AND ("predictive" OR "forecast" OR "anomaly detection") AND ("real-time" OR "RTOS" OR "FreeRTOS" OR "deterministic")) NOT ("wearable" OR "smart home" NOT campus)

String de busca (português):

- (("qualidade do ar" OR "poluição do ar" OR "qualidade do ar interior") AND ("campus inteligente" OR "campus universitário" OR "ensino superior") AND ("IoT" OR "LoRaWAN" OR "FIWARE" OR "ChirpStack") AND ("preditivo" OR "previsão" OR "detecção de anomalias") AND ("tempo real" OR "RTOS" OR "FreeRTOS" OR "determinístico")) NOT ("vestível" OR "casa inteligente" NOT campus)

6.1 Critérios de Inclusão e Exclusão

Critérios	Tipo
Artigos disponíveis na Internet	Incluso
Texto completo em português ou inglês	Incluso
Publicação posteriores a 2021	Incluso
Utilizem Aprendizagem de máquina para predição ou detecção de anomalias	Incluso
Que mencionem tempo real ou RTOS	Incluso
Estudos de caso em campus universitário ou ambiente similar	Incluso
Apenas medição passiva sem modelo preditivo; apenas simulação sem hardware real; revisões sem dados primários	Excluído
Reprodutibilidade são inexistentes ou não avaliadas	Excluído

Justificativa:

Os critérios foram definidos para selecionar estudos diretamente relacionados ao aprimoramento do IQArMobi, priorizando arquiteturas IoT modulares (LoRaWAN/FIWARE), atributos de qualidade (tempo real, escalabilidade) e avaliação de sistemas preditivos com IA. Excluem-se trabalhos sem predição, sem RTOS ou fora do contexto de smart campuses, garantindo o foco na evolução do agente inteligente com resposta automatizada para a região amazônica, em linha com lacunas identificadas por al. (2019), WANG *et al.* (2023) e BENAMMAR (2018).

6.2 Critérios de Qualidade

Critérios	Nota
1. O artigo descreve claramente a arquitetura do sistema	(0 a 2)
2. Os sensores e atuadores utilizados são especificados	(0 a 2)
3. A solução foi validada em ambiente real (campus, campo) e não apenas em simulação?	(0 a 2)
4. O estudo apresenta métricas quantitativas de desempenho (acurácia, RMSE, latência, consumo)?	(0 a 2)
5. Há preocupação explícita com requisitos de tempo real (latência máxima, deadline, jitter)?	(0 a 2)
6. O estudo é recente (últimos 5-6 anos, alinhado com o estado da arte)?	(0 a 2)

CLASSIFICAÇÃO = Somatória das notas dos critérios (N)

OBS:

$N \geq 80\%$ (Excelente)

$60\% \leq N < 80\%$ (Muito Boa)

$40\% \leq N < 60\%$ (Boa)

$20\% \leq N < 40\%$ (Média)

$N < 20\%$ (Baixa)

6.3 Lista dos artigos encontrados

Nº	Título do artigo	Autores	Ano	Veículo
1	Aplicação de TinyML em Sensores Virtuais para Monitoramento da Qualidade do Ar em Ambientes Industriais	Tayco Murilo Santos Rodrigues	2024	Repositório Institucional da Ufal – RIUFAL
2	A Machine Learning-based Decision Support System for IoT Monitoring Solutions	Edgar Filipe Loureiro Ladeira	2024	Repositório Digital da Universidade Beira Rio - uBibliorun
3	Estudo e desenvolvimento de um sensor sem fio inteligente para monitoramento distribuído de poluentes atmosféricos no contexto de cidades inteligentes	Mariana Rodrigues Villarim	2020	Repositório Digital da Universidade Federal da Paraíba - REPO-UFPB
4	FreeRTOS Application in a Real-Time Air Quality Monitoring Architecture for Smart Campus	Elton Alves and Noedson Romario Vieira da Silva and Warley Júnior and Alife Moraes and Nandson Silva and Andson Balieiro	2025	IEEE Latin America Transactions
5	Arquitetura de Monitoramento de Qualidade de Ar baseada no LoRaWAN e FIWARE em um Campus Universitário	Cunha et al.	2024	Anais do XV Workshop de Computação Aplicada à Gestão do Meio Ambiente e Recursos Naturais
6	IQArMobi: Classificação Inteligente da Qualidade do Ar e Ciente de Localização em Ambientes Externos e Internos	Eusébio Thaylor and Nandson Cunha and Alife Moraes and Warley Junior and Elton Alves	2025	Anais do XVI Workshop de Computação Aplicada à Gestão do Meio Ambiente e Recursos Naturais

Lista dos artigos incluídos

Nº	Título do artigo	Autores	Ano	Veículo
1	Air-Pure Monitor: Uma Solução IoT de Baixo Custo para Ambientes Internos Saudáveis	Bruna M. O. Silva, Iwens G. S. Junior, Renato F. Bulcão-Neto	2025	Anais (SBCUP)
2	Real-time Air Quality Monitoring in Smart Cities using IoT-enabled Advanced Optical Sensors	Anushree A. Aserkar and Sanjiv Rao Godla and Yousef A.Baker El-Ebiary and Krishnamoorthy and Janjhyam Venkata Naga Ramesh	2024	International Journal of Advanced Computer Science and Applications
3	Um aplicativo para gerar recomendações e alertas sobre a qualidade do ar em um smart campus	Pablo Leon Rodrigues	2020	Repositório Digital da Universidade de Passo Fundo - REPO-UPF
4	Monitoramento da qualidade do ar em ambientes internos utilizando sensores de baixo custo e aprendizado de máquina	Ana Carolina Camargo Francisco and Felipe Hashimoto Fengler and Gustavo Faria and Iara Negreiros and Luciana Gomes Pereira Pinto and Maurício Tolotto and Raquel Barbosa Rogoschewski and Regiane Relva Romano and Roberto Silva Netto	2023	Universidades & Sustentabilidade

Lista de artigos excluídos Avaliação dos Estudos com Base nos Critérios de Qualidade

A qualidade dos estudos primários foi avaliada com base em cinco critérios (C1 a C5), pontuados de 0 a 2, totalizando até 10 pontos. Os critérios contemplam aderência a arquiteturas IoT modulares (C1), atributos de qualidade como tempo real (C2), descrição de métodos de desenvolvimento (C3), avaliação empírica em ambiente real (C4) e uso de IA ou aderência ao tema de monitoramento da qualidade do ar em smart campuses (C5). A pontuação foi convertida em percentual, classificando os estudos como Excelente ($\geq 80\%$), Muito Boa (60-80%), Boa (40-60%), Média (20-40%) ou Baixa ($< 20\%$).

Nº	Artigo (Autor/Ano)	C1	C2	C3	C4	C5	Total (N)	(%)	Classificação
1	Alves (2025)	2	2	2	2	2	10	100%	Excelente
2	Edgar (2024)	2	2	2	2	1	9	90%	Excelente
3	Rodrigues (2024)	2	2	2	1	1	8	80%	Muito Boa
4	Eusebio (2025)	2	2	2	1	1	8	80%	Muito Boa
5	Villarim (2020)	2	2	1	1	1	7	70%	Muito Boa
6	Cunha (2024)	2	2	1	1	1	7	70%	Muito Boa

6.4 Análise dos Resultados

A seguir, é apresentada uma análise integrada dos seis trabalhos técnico-científicos analisados, todos voltados ao monitoramento da qualidade do ar usando IoT, aprendizado de máquina e sistemas embarcados. Os estudos foram agrupados por abordagem e escopo para facilitar a comparação crítica.

1. Tabulação de resultados (Dados quantitativos)

Trabalho	Tecnologias	Poluentes	Métricas	Resultados quantitativos
FreeRTOS em Smart Campus (Silva et al., 2024)	ESP32-LoRa, FreeRTOS, MQ131/MQ135, LoRaWAN	CO, CO ₂ , O ₃ , NH ₃ , CH ₄	Throughput TX/RX, intervalo de transmissão, taxa de sucesso	Com RTOS: TX=178,23; RX=164,18; intervalo=5,03s; sucesso=88,7%. Sem RTOS: TX=110,97; RX=99,41; intervalo 8s; sucesso=83,3%. Ganho de 37,5% no intervalo.
RuraLTHINGS (Ladeira, 2025)	ESP32-LoRa, FIWARE, LSTM/Bi-LSTM, ARIMA, FCM	Radão, CO, CO ₂ , temperatura, humidade	MSE, MAE, RMSE, R ² , sMAPE, tempo de inferência	Melhor modelo (Bi-LSTM+LSTM): R ² =0,95; MAE=1,14; MSE=3,96. Inferência média=49μs (no ESP32).
Sensor PPD42NS (Villarim, 2020)	ESP32-LoRa, PPD42NS, MQ, RNA, LoRa	MP _{2,5} , CO, CH ₄ , GLP, H ₂ S, VOC	Correlação linear, PDR, RSSI, acurácia	Calibração PPD42NS: R ² =0,967. RNA para gases: acurácia=100% (álcool/água/ar). LoRa em urbano: PDR>95% a 4km; em floresta: perda total.
FIWARE no Campus (Cunha et al., 2024)	ESP32-LoRa, FIWARE, MQ9/MQ131/MQ135/DHT11	CO, CO ₂ , O ₃ , CH ₄ , acetona	Concentrações (ppm), IQAr	CO: até 25 ppm (galpão). CO ₂ : até 220 ppm. CH ₄ : >80 ppm (laboratórios). Acetona: até 60 ppm. O ₃ : baixo (10 μg/m ³).
IQArMobi (Thaylor et al., 2025)	ESP32-LoRa, FIWARE, ML (LR, RF, SVM, GBC), haversine	CO, CO ₂ , CH ₄ , O ₃ , NH ₃ , etc.	Acurácia, precisão, recall, F1	Logistic Regression: acurácia=99%, F1=0,99. Random Forest: 96%. SVM e GBC inferiores.
TinyML para cloro (Rodrigues, 2024)	ESP32-S3, TensorFlow Lite, MLP	Na, K (entrada), Cl (saída)	MSE, RMSE, MAE, R ² , tempo inferência, tamanho modelo	Modelo final: MSE=3,96; MAE=1,14; R ² =0,95; inferência=49μs; redução de tamanho=93,7% (26,5kB → 1,67kB).

2. O que já foi publicado? Os trabalhos abrangem desde 2020 até 2025, com foco crescente em:

- **Comunicação de longo alcance e baixo consumo (LoRa/LoRaWAN):** presente em 5 dos 6 estudos.
- **Middleware para interoperabilidade (FIWARE):** destaque nos trabalhos do grupo da UNIFESSPA (Cunha et al., Thaylor et al.).
- **Aprendizado de máquina embarcado (TinyML):** apenas Rodrigues (2024) explora a predição em microcontrolador com quantização.
- **Sistemas operacionais de tempo real (RTOS):** Silva et al. (2024) é o único a avaliar FreeRTOS no nó sensor.
- **Nariz eletrônico e sensores de baixo custo:** Villarim (2020) e Ladeira (2025) utilizam sensores MQ e PPD42NS.

3. Quais as teorias utilizadas por estudo?

Trabalho	Teorias / Abordagens
Silva et al. 2024	Sistemas de tempo real (RTOS) – escalonamento preemptivo, tarefas concorrentes, redução de latência.
Ladeira 2025	Previsão de séries temporais (ARIMA, LSTM, Bi-LSTM); Redes neurais recorrentes; Sistemas de apoio à decisão.
Villarim 2020	Espalhamento de luz (Teoria de Mie) para MP; Sensibilidade cruzada e nariz eletrônico; Redes neurais artificiais para classificação.
Cunha et al. 2024	Arquitetura IoT em camadas; Middleware FIWARE (Orion, Cygnus); LoRaWAN (ChirpStack).
Thaylor et al. 2025	Aprendizado de máquina supervisionado (classificação); Algoritmo haversine para cálculo de distância; Consciência de localização.
Rodrigues 2024	TinyML (modelos leves para embarcados); Quantização pós-treinamento; MLP para regressão.

4. O que é conhecido até recentemente sobre o tema?

- Monitoramento de qualidade do ar em ambientes urbanos e industriais é viável com sensores de baixo custo (PPD42NS, MQ), desde que calibrados contra equipamentos de referência (ex.: HiVol 3000).
- LoRa/LoRaWAN permite comunicação de longo alcance (4–15 km) com baixo consumo, mas sofre forte interferência de vegetação densa (perda de pacotes mesmo a curtas distâncias).
- Sistemas de tempo real (RTOS) melhoram significativamente a eficiência de transmissão e reduzem latência em nós sensores IoT.

- Aprendizado de máquina é eficaz para classificar a qualidade do ar (99% de acurácia com regressão logística) e para prever concentrações de poluentes ($R^2 > 0,95$ com LSTM).
- TinyML permite inferência em microcontroladores com consumo de energia muito baixo (dezenas de μs , mA) e redução drástica de modelo (até 94%), viabilizando monitoramento em tempo real sem nuvem.

5. Indicadores / Métricas / Critérios e seus valores

Tabela 1: Indicadores, métricas e valores observados nos estudos analisados

Indicador	Trabalhos que utilizam	Valores observados
Throughput (TX/RX)	Silva et al. 2024	TX: 110–178; RX: 99–164
Intervalo de transmissão	Silva et al. 2024	5s (com RTOS) vs 8s (sem)
Taxa de sucesso (PDR)	Silva et al. 2024, Villarim 2020	83–89% (urbano); >95% a 4km; perda total em floresta
Acurácia de classificação	Villarim 2020, Thaylor et al. 2025	99–100%
Erro médio (MAE/MSE)	Ladeira 2025, Rodrigues 2024	MAE=1,14; MSE=3,96
Coefficiente de determinação (R^2)	Ladeira 2025, Rodrigues 2024	0,95–0,97
Tempo de inferência	Ladeira 2025, Rodrigues 2024	49 μs (ESP32)
Redução de tamanho de modelo	Rodrigues 2024	93,7%
Correlação linear	Villarim 2020	$R^2=0,967$ (PPD42NS vs HiVol)
Consumo de corrente	Rodrigues 2024	Média 43,8 mA; pico 49,8 mA

Os principais indicadores quantitativos encontrados nos estudos analisados são apresentados na Tabela 1. A tabela reúne os trabalhos que utilizaram cada indicador e os respectivos valores observados, permitindo relacionar os resultados quantitativos com a comparação crítica apresentada posteriormente. Esses dados fundamentam a comparação apresentada na seção seguinte: as métricas de throughput, intervalo de transmissão e taxa de sucesso permitem avaliar o desempenho da comunicação e do RTOS; as métricas de acurácia, MAE, MSE e R^2 permitem comparar a qualidade dos modelos de classificação e predição; e o tempo de inferência, a redução do tamanho do modelo e o consumo de corrente permitem avaliar a viabilidade da execução da inteligência artificial em dispositivos embarcados. Assim, a tabela não apenas resume os resultados, mas também evidencia que os trabalhos avaliam dimensões distintas e que ainda há uma lacuna na integração entre comunicação, processamento inteligente, tempo real e eficiência energética em uma única solução.

6. Comparações críticas

6.1. Abordagens de comunicação LoRa/LoRaWAN é unânime, mas os testes de Villarim (2020) mostram limitação severa em ambiente florestal (perda total), enquanto Silva et al. (2024) e Thaylor et al. (2025) operam em campus com obstáculos urbanos e obtêm sucesso.

Nenhum trabalho comparou LoRa com outras LPWAN (NB-IoT, Sigfox) no mesmo cenário.

6.2. Modelagem e inteligência artificial Classificação vs. regressão: Thaylor et al. (2025) usam classificação binária (bom/péssimo) com alta acurácia (99%), mas perdem granularidade. Ladeira (2025) e Rodrigues (2024) fazem regressão contínua, mais útil para monitoramento quantitativo.

Modelos estatísticos vs. redes neurais: Ladeira (2025) mostra que ARIMA tem desempenho inferior a LSTM. Rodrigues (2024) confirma MLP simples com quantização já atinge $R^2=0,95$.

TinyML: Apenas Rodrigues (2024) implementa inferência no microcontrolador, demonstrando viabilidade real. Os demais modelos são executados na nuvem ou em PC, limitando aplicações offline.

6.3. Middleware e arquitetura FIWARE é utilizado por Cunha et al. (2024) e Thaylor et al. (2025) para gerenciamento de contexto e persistência. É uma solução madura, mas complexa para pequenos projetos.

Sem middleware: Silva et al. (2024) e Villarim (2020) usam comunicação direta com gateway e nuvem proprietária, mais simples porém menos padronizada.

6.4. Calibração e validação metrológica Apenas Villarim (2020) e Rodrigues (2024) realizam calibração com equipamento de referência (HiVol 3000) ou validação cruzada sistemática. Os demais trabalhos não apresentam comparação com padrões oficiais, fragilizando a confiabilidade dos dados.

6.5. Consumo energético Rodrigues (2024) é o único a medir corrente e estimar autonomia (22h com bateria 1000mAh). Silva et al. (2024) mencionam redução de consumo via RTOS mas não quantificam. Essa lacuna é crítica para aplicações de campo.

7. Lacunas existentes Com base na análise crítica, as principais lacunas ainda não supridas pela literatura (incluindo os trabalhos analisados) são:

Lacuna	Descrição
Integração completa	Nenhum trabalho une coleta por sensores físicos de baixo custo + comunicação LoRa + TinyML + middleware + dashboard em um único sistema validado em campo.
Calibração de sensores MQ em campo	Os sensores MQ (sensibilidade cruzada) raramente são calibrados com misturas gasosas reais; a maioria usa apenas ar limpo ou substâncias simples (álcool, água).
Validação em ambientes industriais reais	Apenas Rodrigues (2024) menciona mineração, mas não testa in loco. Os demais focam campus universitário ou laboratório.
Escalabilidade da rede LoRa	Testes usam poucos nós (1-5). Não há avaliação de colisões, perdas em rede densa ou mecanismos de retransmissão.
Consumo energético detalhado	Ausência de medição de corrente por modo (sleep, sensor ativo, transmissão, inferência). Impacto da quantização no consumo não foi medido.
Explicabilidade dos modelos	Nenhum trabalho analisa a importância das features ou fornece interpretabilidade (SHAP, LIME).
Comparação entre técnicas de quantização	Rodrigues (2024) compara cinco técnicas, mas não mede o impacto no consumo de energia, apenas tamanho e precisão.
Monitoramento de múltiplos poluentes em tempo real com TinyML	Os modelos atuais preveem apenas um poluente (cloro, radão) ou classificam AQI binário. Falta um modelo multitarefa embarcado.
Uso de RTOS com TinyML	Silva et al. (2024) mostram ganhos do FreeRTOS para transmissão, mas não para inferência. Nenhum trabalho combina RTOS e TinyML no mesmo nó.
Disponibilidade de datasets públicos	A maioria usa dados próprios não compartilhados, dificultando reprodutibilidade e comparação.

8. Conclusão da análise

Os trabalhos analisados demonstram avanços significativos no monitoramento da qualidade do ar usando IoT e IA, mas ainda são fragmentados. Há uma clara evolução desde sensores isolados (Villarim, 2020) até arquiteturas completas com middleware (Cunha et al., 2024) e classificação inteligente (Thaylor et al., 2025). O TinyML (Rodrigues, 2024) abre caminho para processamento local com baixíssimo consumo, porém ainda não foi integrado com os demais componentes (RTOS, LoRaWAN, FIWARE) em um sistema unificado. As lacunas apontadas indicam oportunidades para pesquisas futuras, especialmente na validação em campo, calibração metrológica e eficiência energética.

7 Lacunas de Pesquisa

A análise comparativa dos trabalhos selecionados evidencia as seguintes lacunas na literatura:

- ausência de integração simultânea entre predição, resposta automatizada e RTOS;
- concentração de estudos em ambientes genéricos, com baixo foco nas particularidades de um smart campus;
- carência de validação em cenário real, com dados locais e monitoramento de múltiplos poluentes;
- ausência de avaliações conjuntas de acurácia, latência, consumo energético e confiabilidade da comunicação;
- pouca integração entre processamento inteligente embarcado, middleware e mecanismos de resposta automatizada.

8 Síntese da Revisão

Os estudos analisados demonstram que o monitoramento da qualidade do ar em ambientes inteligentes pode ser realizado por meio da integração entre sensores de baixo custo, comunicação LoRa/LoRaWAN, plataformas de middleware e técnicas de inteligência artificial. Os resultados também indicam que modelos de classificação e predição são capazes de apoiar a identificação de situações de risco, enquanto o uso de RTOS contribui para reduzir a latência e tornar o fluxo de comunicação mais previsível.

Apesar desses avanços, a literatura ainda apresenta soluções fragmentadas. Os trabalhos analisados geralmente avaliam apenas uma dimensão do problema, como a comunicação, a classificação da qualidade do ar, a predição de poluentes, a execução embarcada ou o consumo energético. Ainda são escassas as propostas que integram, em uma única arquitetura validada em campo, sensores calibrados, LoRaWAN, RTOS, processamento inteligente local, middleware, resposta automatizada e monitoramento de múltiplos poluentes.

Nesse contexto, o IQArMobi aprimorado é proposto como uma arquitetura capaz de integrar essas dimensões em um sistema voltado ao ambiente de smart campus e às condições da região amazônica. A proposta deverá utilizar os dados dos sensores para classificar e prever a qualidade do ar, identificar níveis de risco e acionar alertas ou outras respostas automatizadas. A adoção de processamento embarcado e de requisitos de tempo real será avaliada em conjunto com aspectos de latência, acurácia, consumo energético e confiabilidade da comunicação.

Essa síntese orienta a metodologia e os experimentos, que deverão comparar o desempenho da arquitetura proposta com os resultados encontrados na literatura. As avaliações

serão realizadas por meio de métricas quantitativas de classificação, predição, comunicação, tempo de resposta e consumo de energia, permitindo verificar se a integração proposta reduz as lacunas identificadas.

Referências

AL., H. Mokrani et. Air quality monitoring using iot: A survey. *In: IEEE International Conference on Smart Internet of Things (SmartIoT)*. [S. l.]: IEEE, 2019. p. 127–134. DOI: 10.1109/SmartIoT.2019.00028.

ALVES, Elton *et al.* FreeRTOS Application in a Real-Time Air Quality Monitoring Architecture for Smart Campus. **IEEE Latin America Transactions**, IEEE, v. 23, n. 4, p. 266–273, 2025.

ANJOS GOMES, R. dos; LIMA, R. B. de; VALE BRISIL, T. do. Impact of the fires in the amazon with the incidence of cases of respiratory problems in the population. **Revista Foco**, v. 17, n. 12, p. 1–19, 2024. DOI: <https://doi.org/10.54751/revistafoco.v17n12-004>.

BENAMMAR, M. et al. A modular IoT platform for real-time indoor air quality monitoring. **Sensors**, v. 18, n. 2, p. 581, 2018. DOI: <https://doi.org/10.3390/s18020581>.

CUNHA, N. et al. Arquitetura de Monitoramento de Qualidade de Ar baseada no LoRaWAN e FIWARE em um Campus Universitário. *In: ANAIS do XV Workshop de Computação Aplicada à Gestão do Meio Ambiente e Recursos Naturais*. Brasília/DF: [s. n.], 2024. p. 169–178. DOI: <https://doi.org/10.5753/wcama.2024.3038>.

KUMAR, S.; JASUJA, A. Air quality monitoring system based on IoT using Raspberry Pi. *In: INTERNATIONAL conference on computing, communication and automation (ICCCA)*. [S. l.]: IEEE, 2017. p. 1341–1346. DOI: 10.1109/CCAA.2017.8230005.

KUMAR, T.; DOSS, A. AIRO: Development of an Intelligent IoT-based Air Quality Monitoring Solution for Urban Areas. **Procedia Computer Science**, v. 218, p. 262–273, 2023. DOI: <https://doi.org/10.1016/j.procs.2023.01.008>.

LADEIRA, Edgar Filipe Loureiro. **A Machine Learning-based Decision Support System for IoT Monitoring Solutions**. 2024. Master Thesis – Universidade da Beira Interior, Covilhã. Disponível em: <http://hdl.handle.net/10400.6/19045>.

MIN-ALLAH, N.; ALRASHED, S. Smart campus—A sketch. **Sustainable Cities and Society**, v. 59, p. 102231, 2020. DOI: <https://doi.org/10.1016/j.scs.2020.102231>.

REDDY, B. S. N. et al. A Comprehensive Review on Functional Analysis of Real-Time Operating Systems. *In: 3RD International Conference on Innovative Mechanisms for*

Industry Applications (ICIMIA). [S. l.]: IEEE, 2023. p. 1098–1102. DOI: 10.1109/ICIMIA60377.2023.10426594.

RODRIGUES, Tayco Murilo Santos. **Aplicação de TinyML em sensores virtuais para monitoramento da qualidade do ar em ambientes industriais**. 2024. 51 f. Monografia (Trabalho de Conclusão de Curso (Bacharelado em Engenharia de Computação)) – Instituto de Computação, Universidade Federal de Alagoas, Maceió.

SEPTIAN, B.; MISBAHUDDIN, M.; ARKAN, F. Freertos based air quality monitoring system using secure internet of things. **Jurnal Teknik Informatika (JUTIF)**, v. 3, n. 1, p. 147–153, 2022. DOI: <https://doi.org/10.20884/1.jutif.2022.3.1.172>.

SILVA, N. *et al.* FreeRTOS Application in a Real-Time Air Quality Monitoring Architecture for Smart Campus. **IEEE Latin America Transactions**, v. 23, n. 4, p. 1–8, 2025. DOI: 10.1109/TLA.2025.10930347.

THAYLOR, Eusébio *et al.* IQArMobi: Classificação Inteligente da Qualidade do Ar e Ciente de Localização em Ambientes Externos e Internos. *In: ANAIS do XVI Workshop de Computação Aplicada à Gestão do Meio Ambiente e Recursos Naturais*. Maceió/AL: SBC, 2025. p. 216–225. DOI: 10.5753/wcama.2025.9015. Disponível em: <https://sol.sbc.org.br/index.php/wcama/article/view/36099>.

UGARTE, L. F. *et al.* LoRa communication as a solution for real-time monitoring of IoT devices at UNICAMP. *In: INTERNATIONAL Conference on Smart Energy Systems and Technologies (SEST)*. [S. l.]: IEEE, 2019. p. 1–6. DOI: 10.1109/SEST.2019.8849100.

VILLARIM, Mariana Rodrigues. **Estudo e desenvolvimento de um sensor sem fio inteligente para monitoramento distribuído de poluentes atmosféricos no contexto de cidades inteligentes**. 2020. Dissertação (Mestrado em Engenharia Elétrica) – Universidade Federal da Paraíba, João Pessoa. Disponível em: <https://repositorio.ufpb.br/jspui/handle/123456789/20464>.

WANG, H. *et al.* Research on Real-time Monitoring System of Multiscenario Health Data Based on Internet of Things. *In: 3RD International Conference on Digital Society and Intelligent Systems (DSInS)*. [S. l.]: IEEE, 2023. p. 332–336. DOI: 10.1109/DSInS60115.2023.10455560.